

基于可观测掩码与扰动归因的多模态情感预测

摘要

文本语义、语音韵律与面部活动共同构成情感表达，但三者的采样尺度不同，局部缺失还会改变预测依据。围绕特征时间对应、缺失条件下的联合预测及决策解释，本文建立词区间聚合模型、带可观测掩码的三支 Transformer，并以扰动归因分析模型对输入的依赖。

针对问题一，以 CTC 强制对齐估计词边界，按词区间与音视频帧支撑区间的交集时长加权聚合，得到 768 维文本、70 维音频和 61 维视觉表示，并以独立掩码保留观测有效性。100 段视频的有效词覆盖率为 91.3%，有效人脸帧占抽样帧的 71.61%；裁剪对照使零人脸片段从 24 段降至 5 段，说明画面尺度处理能够改善检出覆盖，但仍需核实所检人物与说话人的对应关系。

针对问题二，在官方对齐特征上建立极性分类与强度回归的联合预测模型。三路时序编码分别排除不可观测位置，以内容覆盖率辅助融合，并通过连续区间遮蔽及单模态辅助监督训练。在 728 条验证样本上，三模型集成的准确率为 63.74%，宏 F1 为 0.6173，MAE 为 0.5984，Pearson 相关系数为 0.6469。54 种模拟缺失场景表明，遮蔽文本的组合宏 F1 均值为 0.5614，低于保留文本组合的 0.6154；模型对文本局部缺失更为敏感。

针对问题三，在上述固定预测器上精确枚举三模态子集，以 Shapley 值分解类别与强度贡献，再通过局部窗口替换定位证据，并将候选映射至原文、估计语音时段及视频帧。在 123 条验证样本中，首选文本窗口经原词遮蔽重编码后使原类别概率平均下降 0.1432，随机窗口为 0.0518，首选窗口影响更大的比例为 73.17%。结果支持所选文本证据具有模型响应意义；其语义合理性及音视频时间定位仍受参考输入和对齐误差限制。文中汇总了附件 3 的 30 条预测以及附件 4 的 20 条预测与解释。

关键词：多模态情感预测；Transformer；时间对齐；局部缺失；Shapley 归因

目录

摘要	1
1 问题重述与研究思路.....	4
1.1 三个问题及其联系.....	4
1.2 需要解决的关键困难.....	4
1.3 数据范围与研究边界.....	5
2 模型准备	5
2.1 数据预处理与输入组织.....	5
2.2 基本假设.....	5
2.3 主要符号.....	6
3 问题一：三模态特征与时间对应模型.....	6
3.1 特征选择与表示.....	6
3.2 基于词区间的跨模态聚合	7
3.3 质量评价与全量结果.....	8
3.4 裁剪修正的收益与风险.....	9
3.5 本问结果分析.....	10
4 问题二：基于可观测掩码的三支 Transformer.....	10
4.1 内容掩码与可观测掩码.....	10
4.2 分支时序编码与覆盖率融合	11
4.3 连续缺失增强与训练目标.....	12
4.4 评价指标与对照设计.....	13
4.5 表示结构与训练策略的比较.....	13
4.6 基础性能及错误分布.....	14
4.7 缺失模态、长度与位置的影响.....	15
4.8 附件 3 推理.....	16
5 问题三：基于 Shapley 分解与局部扰动的预测解释	17
5.1 固定预测器与解释对象.....	17
5.2 三模态的组级 Shapley 分解.....	17
5.3 局部证据的选择与重编码检验.....	17
5.4 原始素材中的证据定位.....	18
5.5 验证集上的解释敏感性.....	18
5.6 附件 4 全量解释与典型案例.....	19

6 模型评价与讨论.....	20
6.1 方法特点与适用范围.....	20
6.2 实验揭示的局限.....	20
6.3 改进方向.....	21
7 结论	21
参考文献	22
附录 A 第一问 100 条样本结果汇总	23
附录 B 附件 4 解释摘要	26
附录 C 复现范围与材料说明	27

1 问题重述与研究思路

1.1 三个问题及其联系

多模态情感分析试图结合语言内容与非语言信号，判断表达的极性和程度。CMU-MOSEI 将这些信息组织为具有时序关系的多模态样本[1]。在本题中，极性为负面、中性、正面三类，强度取值为-3至3；强度为0的标签仅归入中性。强度的符号表示方向，绝对值表示程度，不能将负面类别理解为一个强度数值。

赛题的三个问题对应情感预测的不同环节。问题一要求由原视频及转写构造多模态特征，核心是保留特征位置与原始时间的对应关系。问题二要求在一个或多个模态的连续局部区间不可用时预测情感，核心是利用剩余信息并分析缺失结构的影响。问题三要求同时给出预测与解释，核心是量化模态作用，并将主要依据定位到可回看的原始片段。

三问在研究主题上相互联系，但输入路径并不相同。第一问自主提取的特征用于对齐展示与质量检查，不进入后两问训练。第二、三问使用附件2的官方特征，分别对附件3、4推理。第三问复用第二问最终模型参数，在其外部增加解释计算。图1给出数据与方法之间的实际关系。




图1 三问的数据来源与方法关系；第一问特征不流入后两问训练

1.2 需要解决的关键困难

跨模态表示首先面临时间粒度差异。文字按词或子词组织，声学特征按短时段窗口计算，视频则由离散帧组成。相同数组下标不保证对应相同表达时段，因此需要先确定共同的时间参照。本文选择词区间作为聚合单元：它既能连接转写内容，又能给音视频特征提供明确的局部范围。

第二个困难是零值的含义不唯一。序列补齐、特殊符号、真实的局部缺失都可能表现为无信息位置；部分文本补齐向量又不为零。因而先确定内容位置，再判断各模态是否可观测。缺失位置虽以零值保存，但不参与注意力的键值聚合和有效位置池化。

预测解释还需要与模型输出建立可检验的联系。注意力系数描述网络内部的信息分配，难以直接等同于某条输入对最终预测的贡献。本文采用固定模型的输入干预：先计算不同模态组合带来的输出变化，再定位局部窗口，最后以另一种文本干预核验候选。由此将模态作用、局部证据和响应检验组织为逐层细化的解释过程。

1.3 数据范围与研究边界

表 1 列出本文使用的数据。附件 2 保持题给划分，不将附件 1 标签补入训练。附件 3、4 不提供情感真值，因此本文只报告其预测与解释，不能计算专项集准确率。本文的定量模型评价采用附件 2 验证集，未提供独立盲测泛化结论。

表 1 数据来源、规模与用途

数据	样本数	输入	用途
附件 1	100	原视频、转写和标签对应表	自提特征、对齐展示
附件 2 训练集	3395	官方三模态对齐特征	学习参数与标准化统计
附件 2 验证集	728	官方特征与标签	比较方案、保存权重、分析错误
附件 2 测试集	727	官方特征与标签	本文不报告其模型成绩
附件 3	30	不完整模态专项特征	最终预测
附件 4	20	专项特征与配套素材	最终预测及解释

2 模型准备

2.1 数据预处理与输入组织

第一问的预处理保留样本编号、视频解码时间戳和转写对应关系。音频统一采样率后提取短时特征，视频按固定目标频率抽样，文本分词时保留原文字符范围。对于对齐失败或未检出人脸的位置，保留其在原序列中的位置并记录有效标志，避免删除后造成三种模态相互错位。具体特征定义与覆盖统计见第 3 节。

后两问沿用附件 2 的训练、验证划分。音视频标准化统计仅由训练集可观测行估计，验证与专项推理使用相同参数；文本特征由固定 BERT 表示。文本补齐由注意力掩码识别，音视频观测有效性在内容位置内判定。该处理将序列补齐与内容缺失分开，使两者不会在模型中被当作同一种时间结构。第一问的标签与自提特征均不补入后两问训练。

统计口径随研究对象确定。第一问总体覆盖率以词数或抽样帧数为分母；第二问性能以样本为单位计算，并区分单模型指标均值与集成预测指标；第三问的局部证据检验以符合窗口条件的验证样本为单位。后文分别给出各项统计的样本范围。

2.2 基本假设

(1) 给定转写是强制对齐的目标词序列。对齐过程估计词出现的时间，不独立证明转写与真实发音完全一致。

(2) 解码时间戳可作为原视频内部的时间坐标。CTC 输出的词边界是估计值，其置信度用于筛查低可靠位置，不视为人工边界误差的替代指标。

(3) 官方音视频特征在有效内容位置上的全零行被操作性地视为不可观测。该规则不推断零值的形成原因；自然缺失与人为遮蔽分别记录。

(4) 连续区间遮蔽能够用于检验局部缺失敏感性，但模拟分布不完全代表专项集或真实采集中的缺失分布。

(5) 参考输入替换后的预测变化反映固定模型对输入的依赖。它不构成人物情绪的因果解释，也不意味着被遮蔽后的输入仍符合自然数据分布。

2.3 主要符号

表 2 主要符号及其含义

符号	含义	取值或维度
$I_j=[s_j, e_j]$	第 j 个词的估计时间区间	秒
A_k, V_l	音频帧、视频帧支撑区间	秒
c_{it}	样本 i 的内容位置标志	0 或 1
o_{it}^m	模态 m 在位置 t 的可观测标志	0 或 1
h_i^m, ρ_i^m	模态池化表示及覆盖率	96 维; $[0,1]$
$p_i, \hat{y}_i$	三类概率及强度预测	3 维; $[-3,3]$
J	本地综合验证分	越小越好
ϕ_m^c, ϕ_m^r	类别概率、强度的模态贡献	带符号数值
$d_{m,l}$	局部窗口的类别支持度	概率差

3 问题一：三模态特征与时间对应模型

3.1 特征选择与表示

文本用于表达语义内容，声音用于描述短时声学变化，视觉用于描述面部活动。三种表示不需要具有相同维度；对齐要求它们对应同一段表达，而非逐维语义一致。表 3 给出自提特征与官方特征的区别。

表 3 第一问特征定义与后两问输入维度

模态	第一问维度	第一问组成	官方维度
文本	768	冻结 BERT 的逐子词隐藏状态	768
音频	70	25 维 LLD+20 维 MFCC+20 维差分+5 维统计量	74
视觉	61	52 维 blendshape+3 维姿态角+6 维几何比值	35

文本采用 bert-base-uncased[2]。分词器输出子词及其原文字符范围，BERT 为每个子词生成上下文表示。模型在特征提取中保持冻结。由于一个词可能被拆成多个子词，本文保留词—子词映射，不将二者混为同一粒度。

音频统一为 16 kHz。短时分析窗口为 400 个采样点，步长 160 个采样点，分别对应 25 ms 与 10 ms。openSMILE 提取 eGeMAPSv02 的 25 维低层描述量[3]；librosa 提取 20 维 MFCC、其一阶差分，

以及 RMS、过零率、谱质心、谱带宽、谱滚降点[4]。例如窗口内 RMS 可写为式（1），它反映短时幅度大小，但不能单独确定情感极性。

$$R_k = \sqrt{\frac{1}{N} \sum_{n=1}^N u_k(n)^2} \quad (1)$$

两套工具的帧中心网格不同，先把 openSMILE 输出按时间线性插值到 librosa 网格，再拼接成 70 维向量。设 t 处于相邻帧中心 τ_a 与 τ_b 之间，单维插值为式（2）；边界外采用端点值。这一步统一音频内部时间网格，不用于补齐视觉缺陷。

$$f(t) = \frac{\tau_b - t}{\tau_b - \tau_a} f(\tau_a) + \frac{t - \tau_a}{\tau_b - \tau_a} f(\tau_b) \quad (2)$$

视觉按约 10 帧/秒抽样，保存解码时间戳。MediaPipe Face Landmarker 输出的面部混合形状分数、姿态矩阵及关键点用于构成 61 维表示[5]。其中几何比值对距离进行归一化，以减小画面尺度变化的直接影响。未检出人脸的帧以零值存储，同时令有效标志为 0；不能把该帧解释成“没有表情”。

3.2 基于词区间的跨模态聚合

采用 wav2vec2-base-960h 生成 CTC 帧级概率，并在给定目标文本约束下寻找最佳路径[6]。设目标字符序列为 a ，允许路径集合为 $\Pi(a)$ ，则最大概率路径满足式（3）。本过程属于强制对齐，不是自由语音识别。

$$\pi^* = \arg \max_{\pi \in \Pi(a)} \sum_{t=1}^T \log P(\pi_t | u) \quad (3)$$

根据路径中属于同一词的帧得到起止时间 I_j 。词置信度为被分配字符帧的目标概率均值；低于 0.1 或目标文本不受支持时，该词不能为音视频聚合提供有效时间。分词器字符范围将子词映射到与其重叠最多的原词。

对于词区间 I_j 与音频帧支撑区间 A_k ，令 q_k 表示帧有效性，交集时长及权重和定义为式（4）。

$$w_{jk} = q_k \max(0, \min(e_j, b_k) - \max(s_j, a_k)), \quad W_j = \sum_k w_{jk} \quad (4)$$

当 W_j 大于 0 时，词级音频表示为式（5）；否则存储零向量并将掩码置 0。视觉采用同样的聚合形式，将音频帧替换为有效人脸帧。

$$g_j = \frac{\sum_k w_{jk} a_k}{W_j}, \quad W_j > 0 \quad (5)$$

视频帧支撑边界取相邻抽样时间戳的中点，首尾受视频时长约束，避免用标称帧率反推时间。属于同一词的子词共享其音视频聚合向量；文本侧仍保留各自的 BERT 向量。[CLS]、[SEP]及补齐位置不对应实际词时间，其音视频掩码为 0。图 2 展示从不同帧率到词区间的聚合关系。




图2 词区间聚合示意；区间为说明机制而绘制，不是实测样本

长度约束施加在子词序列上。完整表示按真实子词数保存；为形成定长输入，每窗最多保留48个内容子词，加首尾特殊符号后补至50，相邻窗口起点间隔38个内容子词。本批样本有94条仅需一窗、6条需两窗，完整token数为7—84。因此，50表示存储位置上限，位置所覆盖的物理时长由词边界决定，并不均匀。

区间交集权重均非负，归一化后和为1，因而式（5）是观测帧向量的凸组合。当词跨越多个帧时，各帧按实际重叠时长参与表示；没有有效重叠时则由掩码显式记录缺失。这一构造保留了时间对应关系，但加权平均会平滑词内的短时变化。保存原始帧级序列，可供后续回看这些被聚合压缩的细节。

3.3 质量评价与全量结果

没有人工词边界和目标人物真值时，不能直接计算对齐准确率。本文分别统计词覆盖率与人脸帧检出率，定义为式（6）。样本均值与总体微平均的权重不同，不能混用。

$$C_i^w = \frac{N_i^{validword}}{N_i^{word}}, \quad C_i^v = \frac{N_i^{validface}}{N_i^{sampledframe}} \quad (6)$$

样本出现未解决词、疑似人脸切换，或有效人脸帧低于抽样帧的一半时，自动标记为REVIEW；其余为PASS。PASS只表示未触发这些规则。图3以每条视频为单位展示两项指标，表4给出总体数量。




图3 第一问词覆盖与人脸检出的分布；每个点对应一条视频

表 4 第一问基础版本自动核验结果

项目	数值	解释
样本数	100	全量处理
PASS / REVIEW	37 / 63	自动规则状态
有效词 / 总词	1764 / 1932	微平均 91.3%
未解决词	168	156 低 CTC 分数，12 目标文本不受支持
有效人脸帧 / 抽样帧	5595 / 7813	微平均 71.61%
零人脸片段	24	原始未裁剪画面
有效音频 / 视觉 token	2111 / 1562	由词时间聚合后有效的位置

词覆盖率较高并不保证视觉可用。图 4 所示样本的词时间和人脸观测均可形成对应关系；与之对照，样本-571d8cVauQ\$_S0 的词对齐未出现未解决词，但原画面的 52 个抽样帧均未检出人脸。二者的视觉可用性不同，因此质量分析需要按模态分别进行。




图 4 典型样本的词时间、声音能量、人脸状态与原画面对应

3.4 裁剪修正的收益与风险

对零人脸片段尝试中心裁剪后，多数片段恢复了检出。进一步形成的候选版本在 27 条视频中采用裁剪，有效人脸帧增至 7110，零人脸片段降至 5，有效视觉 token 增至 2008；词对齐保持不变。图 5 比较两版的覆盖情况。




图 5 裁剪候选提高了检出覆盖，但尚未完成目标人物身份核验

裁剪改变了人脸相对尺度及画面内容，能够改善部分远景中的检测条件，也可能纳入非说话人物。因此，检出覆盖的提高只说明更多帧具有可提取的人脸表示，尚不足以证明目标身份正确。本文以基础版本统计第一问全量结果，将裁剪版本列为预处理对照。附录 A 汇总基础版 100 条样本，逐样本向量、掩码与时间记录随特征文件保存。

3.5 本问结果分析

词级聚合把异步帧序列转换为共享位置的多模态表示，同时保留了各模态独立的有效性。词覆盖与视觉检出之间的差异说明，单一“处理成功率”不足以评价整个流程：词时间可靠的样本仍可能没有可用人脸，反之亦然。本文据此采用分模态质量统计，并把自动筛查与原始素材回看结合。现有结果能够评价特征可用范围；若要进一步估计时间边界误差或人物识别正确率，仍需相应人工标注。

4 问题二：基于可观测掩码的三支 Transformer

局部连续缺失同时改变序列的可用位置和模态的信息量。为保留未受影响的局部内容，本文先分别编码三种模态，在注意力与池化阶段显式使用可观测掩码，再将分支表示和覆盖率共同输入融合层。模型以共享表示完成极性分类和强度回归，并用连续遮蔽模拟训练时的局部信息损失。

4.1 内容掩码与可观测掩码

官方对齐输入的文本、音频、视觉维度分别为 768、74 和 35，序列槽位数为 50。文本内容位置由 text_bert 的注意力掩码和特殊符号界定，记为 c_{it} 。文本可观测掩码初始取内容掩码；音视频在内容位置上满足至少一维绝对值大于 10^{-6} 时记为可观测。

$$o_{it}^m = c_{it} \cdot 1\{\max_d |x_{itd}^m| > 10^{-6}\}, m \in \{A, V\} \quad (7)$$

这一区分十分必要：验证集 728 条中，85 条至少存在一个音视频内容位置的全零行，其中视觉 85 条、音频 1 条。原样验证条件表示“不追加人为遮蔽”，不代表输入天然完整。文本补齐位置则不能单靠是否全零判断。

音视频每维的均值 μ 和标准差 σ 仅用训练集可观测行估计。验证与专项推理使用同一统计量；不可观测行在标准化后再次置零，如式 (8)。

$$\tilde{x}_{itd}^m = o_{it}^m \frac{x_{itd}^m - \mu_d^m}{\max(\sigma_d^m, 10^{-6})} \quad (8)$$

附件 3 没有直接提供 768 维文本向量，因此由其 `text_bert` 输入调用固定版本 BERT 重建。训练中的文本遮蔽也采用重编码：若仅把被遮位置的缓存向量置零，其余 BERT 位置仍可能携带被遮词的上文信息。将目标 `token` 替换成[MASK]后重新编码，可以更直接地改变原词输入。

4.2 分支时序编码与覆盖率融合

为使各路缺失分别处理，文本、音频和视觉先独立编码。各分支将输入线性投影至 96 维，经 LayerNorm 后加入位置嵌入，如式 (9)。位置向量用于区分同一模态中的序列位置。

$$u_{it}^m = LN(W_m \tilde{x}_{it}^m + b_m) + e_t^m \quad (9)$$

每个分支采用一层、四头 Transformer，前馈隐藏维度 192，dropout 为 0.1。单个注意力头的计算形式为式 (10)，其中 B 的不可观测键位置取负无穷，其他位置取 0[7]。

$$Z = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}} + B\right)V \quad (10)$$

对无可观测位置的分支，计算中临时保留安全位置以避免全屏蔽造成数值异常，最终输出仍归零。时序输出 z 经掩码均值池化，覆盖率同时保留，如式 (11)。分母以内容长度为基准，因此 ρ 能够反映当前样本的信息完整度。

$$h_i^m = \frac{\sum_t o_{it}^m z_{it}^m}{\max(1, \sum_t o_{it}^m)}, \quad \rho_i^m = \frac{\sum_t o_{it}^m}{\max(1, \sum_t c_{it})} \quad (11)$$

三路 96 维表示与三个覆盖率拼成 291 维输入，经 128 维共享层生成融合表示。采用覆盖率的原因是，掩码均值池化会将不同观测数量归一到相同尺度，仅凭池化向量不一定能区分短片段与较完整的观测。显式加入覆盖率，为融合层提供了信息完整度线索。最终模型采用直接拼接：覆盖率对预测的影响由网络学习，不预设其与模态作用单调对应。图 6 给出模型结构。

$$h_i = \text{Dropout}(\text{ReLU}(W_f[h_i^T; h_i^A; h_i^V; \rho_i^T; \rho_i^A; \rho_i^V] + b_f)) \quad (12)$$

分类和回归共享 h_i ，但使用不同输出头。分类概率取 `softmax`，强度采用 `3tanh` 限幅，如式 (13)。这能保证强度范围，却不能保证两个头的符号始终一致。

$$p_i = \text{softmax}(W_c h_i + b_c), \quad \hat{y}_i = 3 \tanh(w_r^T h_i + b_r) \quad (13)$$




图 6 三支时序编码、覆盖率拼接与辅助监督；虚线部分仅用于训练

在各单模态池化表示上设置三分类与强度辅助头，目的是对分支施加直接的任务约束。该设计参考了 EMOE 关注单模态预测能力的思路[8]，但本文没有实现其专家混合与单模态蒸馏机制。最终网络共有 353264 个可训练参数，冻结 BERT 不计入这一数量。

4.3 连续缺失增强与训练目标

随机逐点删除与连续时间段缺失不同。本文在每轮训练中，为每条样本生成一个连续区间遮蔽视图。以 0.75 概率选择单模态，以 0.25 概率选择双模态；单模态 T/A/V 或双模态 TA/TV/AV 各自在组内等概率抽取。名义长度比例 r 从 0.1、0.3、0.5 中等概率选择，内容长度为 L 时，遮蔽长度为式 (14)。

$$\ell = \min(L, \max(1, \lceil rL \rceil)) \quad (14)$$

起点从合法内容位置中随机抽取；双模态使用同一所选区间。若没有实际删除有效信息或导致三模态全部不可用，则重新抽样。整数取整会使短文本的实际比例高于名义比例，且自然零段会影响实际新增缺失量。因此 10%、30%、50% 是抽样规则，不是每条样本最终损失的信息比例。

融合头采用类别加权交叉熵与 Huber 回归损失。类别权重取训练样本数平方根的倒数并归一化，如式 (15)。类别权重降低多数类对目标的直接支配，但不能消除类别边界重叠。

$$\alpha_c = \frac{n_c^{-1/2}}{\frac{1}{3} \sum_{k=1}^3 n_k^{-1/2}} \quad (15)$$

对一个批次，交叉熵按照目标类别权重归一化；Huber 损失在残差绝对值不超过 1 时为平方项，否则为线性项，可用式 (16) 统一表达。

$$H(e) = \frac{1}{2} \min(|e|, 1)^2 + \max(|e| - 1, 0) \quad (16)$$

$$L_{main} = \frac{-\sum_i \alpha_{y_i^c} \log p_{i, y_i^c}}{\sum_i \alpha_{y_i^c}} + \frac{1}{n} \sum_i H(\hat{y}_i - y_i^r) \quad (17)$$

辅助损失在每个模态内对有观测的样本取加权交叉熵项与 Huber 项的平均，再对当前有观测样本的模态取平均。融合头与辅助头均监督极性和强度。原样视图 x 和遮蔽视图 x' 共享网络参数，完整目标为式 (18)。

$$L = L_{main}(x) + L_{main}(x') + \frac{0.1}{2} [L_{aux}(x) + L_{aux}(x')] \quad (18)$$

训练目标由式 (18) 的监督项构成。三个种子均训练 30 轮，按验证准则分别保存第 5、7、4 轮的参数；继续训练后的参数不自动替代验证表现更好的权重。推理时，对三个模型的分类概率和强度分别取算术平均，辅助头仅用于训练，不参与预测投票。表 5 列出求解设置。

表 5 最终模型训练设置

参数	设置
随机种子	20260923、20260924、20260925
优化器	AdamW
学习率 / 权重衰减	0.0003 / 0.01
批量大小 / 训练轮数	64 / 每种子 30 轮
分支维度 / 层数 / 注意力头	96 / 1 / 4
FFN 维度 / dropout	192 / 0.1
辅助损失系数	0.1
缺失区间	单个连续区间，单或双模态

4.4 评价指标与对照设计

极性任务报告 Accuracy 与宏平均 F1，强度任务报告 MAE 与 Pearson 相关系数。宏 F1 对三类等权，能够揭示中性类较弱而总体准确率掩盖的问题。式（19）—（21）给出定义，P_c 和 R_c 分别为类别精确率与召回率。

$$Acc = \frac{1}{n} \sum_i 1(\hat{c}_i = c_i), \quad F_{macro} = \frac{1}{3} \sum_{c=1}^3 \frac{2P_c R_c}{P_c + R_c} \quad (19)$$

$$MAE = \frac{1}{n} \sum_i |\hat{y}_i - y_i| \quad (20)$$

$$r_p = \frac{\sum_i (y_i - \bar{y})(\hat{y}_i - \bar{\hat{y}})}{\sqrt{\sum_i (y_i - \bar{y})^2 \sum_i (\hat{y}_i - \bar{\hat{y}})^2}} \quad (21)$$

在原样验证集之外，构造 6 种模态组合×3 个位置×3 个名义长度比例，共 54 种缺失场景。前、中、后按内容 token 顺序定义，不是将视频物理时长分段。各场景都在同一 728 条验证样本上计算，因此并非 54 个独立数据集。

用于模型比较的本地综合分 J 见式（22），上横线表示 54 种场景平均，F 表示宏 F1。该准则给缺失场景较高权重，反映本问对鲁棒性的关注；它不是主办方评分公式，也不能代替单项指标。

$$J = 0.25(\frac{MAE_0}{3} + 1 - F_0) + 0.75(\frac{\overline{MAE}_{54}}{3} + 1 - \bar{F}_{54}) \quad (22)$$

4.5 表示结构与训练策略的比较

结构比较从掩码均值池化与 MLP 基线开始。该模型不显式建模词序关系，可用于检验时序编码的增益是否足以抵消额外参数与优化难度。加入连续缺失增强后，基线平均 J 由 0.6226 降至 0.6200，但三个种子的变化方向不完全一致；早融合两层 Transformer 的 J 为 0.6269，未超过同预算池化基线。因而，增加时序结构本身并未形成稳定优势。

转为独立分支后，学习率 10^{-3} 的直接拼接模型 J 为 0.6286；仅将学习率降至 3×10^{-4} ，J 降为 0.6141，三个种子方向一致。与此相比，输出一致性系数 0.5 的对照仅使 J 从 0.61408 降为 0.61389，且种子方向不一致，因此未纳入最终目标。

在固定较低学习率后，进一步比较门控、辅助监督、二者组合以及多段遮蔽。表 6 和图 7 给出同批集中实验。门控+辅助头的缺失 MAE 较低，但宏 F1 也下降，呈现分类与回归之间的取舍。

表 6 集中对照实验（三个种子的指标均值）

配置	J ↓	原样宏 F1	缺失宏 F1	缺失 MAE	改善种子
无辅助基准	0.61408	0.61639	0.58887	0.63503	基准
门控	0.61561	0.60954	0.58247	0.62067	1/3
学习率 $1e-4$	0.61959	0.61185	0.58471	0.63925	1/3
辅助头（最终）	0.61432	0.61705	0.58837	0.63519	1/3
门控+辅助头	0.61775	0.60736	0.57985	0.61961	1/3
多段遮蔽	0.61819	0.61190	0.58672	0.63892	1/3




图7 六种配置的综合分与分类—回归取舍；误差棒为三个种子J的标准差

对照采用统一改进判据：J均值至少下降 0.005、至少两个相同种子的结果改善，且缺失 MAE 恶化不超过 0.01。五种修改均未同时满足上述条件。本文后续采用含单模态辅助监督的配置，记为 C_uni，其平均 J 为 0.61432，比无辅助基准高 0.00024。辅助头为分支提供直接监督，但本实验未证明这一设计带来稳定性能提升。因此，辅助监督应作为所用模型的结构描述，其收益仍需更多独立实验支持。


4.6 基础性能及错误分布

最终三种子集成在原样验证集上的 Accuracy 为 63.74%，宏 F1 为 0.61726，MAE 为 0.59843，Pearson 相关系数为 0.64691。这里的“原样”指不增加人工遮蔽，保留数据原有的缺失。表 7 分别报告单模型指标的三种子均值和概率集成后的指标；后者在同一组 728 条样本上重新计算，不等于前者的简单平均。

表 7 最终模型的验证性能

评价口径	Accuracy	宏 F1	MAE	Pearson
三种子指标均值，原样	0.63690	0.61705	0.61271	0.63068
三种子指标均值，54 场景	0.60929	0.58837	0.63519	0.58862
三种子集成，原样	0.63736	0.61726	0.59843	0.64691

图 8 显示中性是当前薄弱类别：184 条中性样本中 88 条预测正确，38 条被判负面、58 条被判正面；中性 F1 为 0.47826，低于负面 0.66513 与正面 0.70840。混淆矩阵说明了错误方向，但没有单独证明这些错误来自表情、语气或语义模糊。具体原因仍需逐例核对文本、强度标签与模型响应。

图 8 验证集三分类混淆矩阵；集成预测， $n=728$

4.7 缺失模态、长度与位置的影响

图 9 分别按模态组合、名义遮蔽长度和位置汇总。T/TA/TV 三组平均宏 F1 为 0.56136，而 A/V/AV 三组为 0.61537，相差约 0.05401；相应 MAE 为 0.65631 和 0.61407。这一差异表明，当前模型在所定义的扰动下明显依赖文本。




图 9 局部缺失敏感性：先按每种子场景计算，再作等权平均

音频、视觉单独被遮以及二者同时被遮时，宏 F1 相对原样分别下降约 0.00157、0.00065、0.00282。数值变化小，只能说明模型对这些局部扰动较不敏感，不能据此认定音视频对所有样本均无用。

名义遮蔽比例从 10% 提高到 30%、50% 时，平均宏 F1 约由 0.6011 降至 0.5886、0.5754，MAE 约由 0.6211 升至 0.6333、0.6511。三档平均结果呈单调恶化，但这不是每个样本或每个种子均单调的证明。前、中、后位置的平均宏 F1 约为 0.5857、0.5920、0.5874，差异小于 0.007；本次结果未显示突出的单一高风险位置，也不足以确定其机制原因。

4.8 附件 3 推理

最终集成对附件 3 输出负面 6 条、中性 9 条、正面 15 条，强度约为-1.361 至 1.270。附件 3 的视频零段可以不止一段，与最终训练的单连续区间增强不完全一致；统一掩码使接口能够处理这些位置，但不能替代专项真值评价。全量结果见表 8。概率为模型输出，未经过校准，不当作正确率。

表 8 附件 3 全量预测

样本	极性	强度	p 负面	p 中性	p 正面
01	负面	-0.756	0.618	0.292	0.090
02	中性	-0.206	0.172	0.660	0.168
03	中性	0.222	0.237	0.489	0.274
04	正面	0.275	0.092	0.317	0.591
05	负面	-1.361	0.896	0.072	0.032
06	正面	0.982	0.022	0.160	0.818
07	中性	0.020	0.243	0.440	0.318
08	中性	-0.002	0.196	0.422	0.382
09	正面	1.190	0.013	0.060	0.928
10	中性	-0.131	0.111	0.755	0.134
11	中性	0.170	0.217	0.466	0.317
12	正面	0.199	0.250	0.248	0.501
13	中性	-0.135	0.313	0.400	0.287
14	负面	-0.894	0.667	0.206	0.127
15	正面	0.594	0.028	0.213	0.759
16	正面	1.270	0.035	0.095	0.871
17	负面	-0.228	0.432	0.371	0.197
18	正面	0.343	0.086	0.449	0.464
19	负面	-0.357	0.524	0.339	0.137
20	中性	-0.001	0.369	0.447	0.184
21	正面	0.383	0.069	0.313	0.618
22	正面	0.273	0.209	0.302	0.489
23	正面	0.330	0.061	0.458	0.481
24	负面	0.094	0.425	0.188	0.387
25	正面	0.185	0.087	0.428	0.486
26	正面	0.728	0.057	0.183	0.760
27	正面	0.257	0.075	0.289	0.636
28	正面	0.348	0.043	0.395	0.562
29	正面	0.397	0.135	0.396	0.469
30	中性	0.141	0.292	0.437	0.271

5 问题三：基于 Shapley 分解与局部扰动的预测解释

5.1 固定预测器与解释对象

问题二得到的预测器已能同时输出极性与强度。第三问在其外部增加解释计算，复用 C_uni 三种子集成的全部参数，使预测变化可归因于输入干预。对每条样本先固定原输入下的预测类别 c ，再比较模态或局部窗口被替换前后该类别概率的变化。分析目标由此限定为模型的输入依赖，不能直接等同于人物真实心理状态。

极性与强度采用不同输出头，解释也应区分目标。某模态可以提高负面类别概率，同时使回归数值减小；这两个变化方向并不矛盾。若直接把强度贡献的正负解释成“支持当前类别”，就会混淆两个任务。

5.2 三模态的组级 Shapley 分解

记模态集合 $M=\{T,A,V\}$ 。对任意子集 S ，保留 S 内特征，用参考值替换其他模态，得到 X_S 。类别和强度评价函数分别见式（23）。本文对三个模态整体做分解，不对 877 个单维特征逐个归因。

$$v_c(S) = p_c(X_S), \quad v_r(S) = \hat{y}(X_S) \quad (23)$$

三个模态只有 8 个子集，可以精确枚举。根据 Shapley 分配原理[9]，模态 m 的贡献是其在不同加入顺序中的边际变化加权平均，如式（24）。

$$\varphi_m^q = \sum_{S \subseteq M \setminus \{m\}} \frac{|S|!(2-|S|)!}{3!} [v_q(S \cup \{m\}) - v_q(S)] \quad (24)$$

其中 q 取 c 或 r 。对任意一种模态加入顺序，三个边际贡献之和均从空子集输出逐项相消至完整输入输出；对所有顺序取平均，便得到式（25）的守恒关系。实现中该关系的数值误差在 10^{-8} 量级，说明贡献分配与查询输出一致。参考输入的选择仍会改变被分解的差值，需要另行考察其敏感性。

$$\sum_{m \in M} \varphi_m^q = v_q(M) - v_q(\emptyset) \quad (25)$$

主分析参考值为训练集有效文本向量均值，以及音视频标准化后的零向量，同时保留原始可观测掩码。另一种参考将整路模态标记为不可用，用于敏感性比较。在可观测模态中，最大正向类别贡献对应主要参考模态。贡献有正有负，不必加和为 1，也不作情绪百分比解释。

5.3 局部证据的选择与重编码检验

用原文字符范围建立原词到 BERT 子词的对应关系。构造连续三词窗口，尾部允许更短候选。对某个模态的窗口 I 使用参考值替换，定义类别支持度 d 和强度变化 Δ ，如式（26）。

$$d_{m,I} = p_c(X) - p_c(X_{m,I \leftarrow ref}), \quad \Delta_{m,I} = \hat{y}(X) - \hat{y}(X_{m,I \leftarrow ref}) \quad (26)$$

每路保留支持度为正、排序靠前的至多两个不重叠窗口。这里的“支持”仅相对于特征替换而言。为进一步核验文本，把候选原词对应的所有子词替换为[MASK]，经冻结 BERT 重新计算，再得到式（27）的原词级响应。

$$d_I^{word} = p_c(X) - p_c(X_{T \leftarrow BERT(mask_I(text))}) \quad (27)$$

若特征层 d 为正而原词层 d 为负，该候选没有通过方向一致性检验，应保留为差异案例。本文借鉴扰动式解释评价关注输出变化的思想[10]，没有使用人工证据真值，因此不会将这种检验称为证据定位准确率。

5.4 原始素材中的证据定位

文本可由字符范围直接返回原句。音视频定位则有额外不确定性：官方特征没有逐行的原始秒数。本文以原文与视频音轨进行 CTC 强制对齐，再将 aligned 位置与词区间关联，得到估计时段；视觉关键帧从该时段附近按真实帧时间戳抽取。

这一映射依赖对齐特征与词序位置的对应假设，不能将重建词时刻称为官方音视频特征时间戳。低置信度或无法映射的候选不填写秒数。原视频回看用于核对说话内容、画面人物和时段是否一致，静态关键帧不能替代听音。

5.5 验证集上的解释敏感性

预测器未改变，因此基础验证指标与第二问相同。解释检验另外按真实类别分层抽取 128 条验证样本，排除 5 条缺少两个可比较窗口的短文本，得到 123 条。先按特征扰动排序选择窗口，再与另一随机三词窗口分别做原词重编码。随机窗口优先选不重叠位置，无合法不重叠窗口时从其他候选中选择。

式 (28) 统计首选窗口比随机窗口影响更大的比例。图 10 同时显示两种平均变化及配对关系，避免只报告一个均值。

$$R_{win} = \frac{1}{n} \sum_i 1(d_{i,top}^{word} > d_{i,random}^{word}) \quad (28)$$




图 10 文本首选窗口与随机窗口的重编码响应； $n=123$ ，虚线为相等参考线

首选窗口平均使原类别概率下降 0.1432，随机窗口为 0.0518；首选优于随机的比例为 73.17%，首选响应为正的的比例为 89.43%。结果支持“筛出的文本窗口在另一种干预下通常仍有较大影响”，但选择与检验仍基于同一预测器，存在选择偏差；该结果不能外推为音视频定位质量或人与模型的解释一致率。

5.6 附件 4 全量解释与典型案例

附件 4 共 20 条样本，预测负面 9 条、中性 4 条、正面 7 条。均值参考下 18 条主要参考文本，2 条参考视觉，0 条参考音频；更换参考方式有 3 条主模态发生变化。图 11 展示全部样本的三路类别贡献，表 9 列出全量预测，附录 B 补充对应解释摘要。




图 11 附件 4 逐样本类别贡献；色彩表示带符号贡献，不是模态权重

表 9 附件 4 全量预测

样本	极性	强度	p 负面	p 中性	p 正面
01	中性	0.230	0.118	0.574	0.309
02	中性	-0.037	0.354	0.389	0.256
03	负面	-0.264	0.517	0.353	0.129
04	负面	-0.279	0.654	0.136	0.211
05	正面	0.415	0.044	0.339	0.618
06	正面	0.741	0.082	0.349	0.569
07	正面	0.711	0.028	0.232	0.739
08	正面	0.319	0.062	0.393	0.546
09	负面	-1.889	0.938	0.034	0.028
10	负面	-1.595	0.890	0.047	0.063
11	负面	-0.882	0.873	0.074	0.053
12	负面	-1.029	0.815	0.134	0.051
13	中性	0.079	0.087	0.583	0.330
14	中性	0.088	0.090	0.502	0.408
15	正面	1.043	0.017	0.097	0.886
16	负面	-2.183	0.970	0.019	0.011
17	正面	1.403	0.014	0.064	0.922
18	负面	-0.474	0.458	0.430	0.112
19	负面	0.133	0.458	0.111	0.431
20	正面	0.969	0.024	0.108	0.868

输出的 75 条正向特征候选包括文本 39、音频 24、视觉 12；69 条有重建时段，6 条因对齐不足未给秒数。文本 39 条中 34 条重编码后方向一致。附件 4 的 13 号样本内容位置上的视觉特征均不可观测，因此其视觉贡献为 0，不列视觉证据。

样本 10 展示了较一致的文本依据。模型预测负面概率 0.890、强度-1.595，文本的类别贡献约+0.861，音频和视觉均约-0.016。“was pretty terrible”对应估计时段 7.51—9.21 秒，原词遮蔽重编码后负面概率下降约 0.274。图 12 将模态贡献、文本候选及视觉案例放在同一组图中，呈现不同层次的依据。




图 12 典型案例的模态贡献与证据回溯；局部条形仅展示已筛选候选，不代表完整重要性分布

样本 05 的主要参考模态为视觉，其对正面类别贡献约+0.056，而对强度数值贡献约-0.021。该例表明类别贡献与强度贡献确有区别，但不能据此推断网络识别到特定表情。样本 19 则提示双头预测的不一致：负面概率约 0.458，正面约 0.431，强度却为+0.133。在无标签条件下，应记录输出冲突而不是直接裁定哪一头正确。

6 模型评价与讨论

6.1 方法特点与适用范围

三部分方法共同保留了“位置—观测—输出”的对应关系。词区间聚合使不同采样频率的表示能够按局部内容组织；可观测掩码让缺失位置在时序编码和池化中得到一致处理；扰动归因将输入变化与预测响应联系起来。三者分别服务于特征构建、鲁棒预测和结果解释，避免把某一环节的成功直接视为整个任务的成功。

模型规模与解释计算均保持可控。时序预测器使用三个单层分支，共 353264 个可训练参数；冻结文本编码器不计入其中。模态归因只需枚举三个模态的 8 个子集，可以计算精确的组级 Shapley 值；局部证据计算的代价则随候选窗口数量增加。这一安排适合本题样本规模，也便于对单条预测进行复核。

6.2 实验揭示的局限

实验也揭示了方法的边界。第一问的 91.3%有效词覆盖及裁剪候选 91.00%人脸帧检出率均为代理指标，人工词边界与目标人物核验尚未完成。第二问的中性 F1 较低，且模型对文本缺失更敏感；更复杂的融合结构没有自动带来稳定收益。所有模型比较反复使用同一验证集，三个种子只能刻画有限的优化波动，不能作为独立泛化证据。

解释方面，参考值和遮蔽方式都会改变结果。Shapley 分解的数值一致性、文本重编码的方向一致性、人与解释的语义一致性是不同层次的要求。当前完成了前两类计算，尚不能替代最后一类人工确认。音视频特征行到秒数的估计映射，也是第三问仍需重点检查的部分。

6.3 改进方向

第一问宜优先核对裁剪后人物身份和低置信度词边界，以区分可用率不足与对象识别错误。第二问宜结合中性类的混淆方向审查具体样本，并在固定预算下比较更贴近连续多段缺失的增强分布。第三问宜补充完整局部窗口的重要性曲线及人工证据标注，分别评价响应忠实性、定位误差和语义合理性。这些工作针对的是现有实验已经暴露的问题，不能由扩大网络规模直接替代。

7 结论

本文围绕多模态情感预测的时间对应、局部缺失和决策解释建立了相互衔接的方法。基于词区间交集的聚合实现了 100 条原视频的特征构建；有效词覆盖率为 91.3%，人脸帧有效比例为 71.61%，反映出两类观测具有不同的质量瓶颈。

带可观测掩码的三支 Transformer 在 728 条验证样本上取得 63.74% 的三分类准确率及 0.5984 的强度 MAE。连续缺失实验显示，文本被遮蔽及缺失比例增大时性能下降较明显；中性识别仍是薄弱环节。辅助监督和门控对照未显示稳定增益，说明结构复杂度不能替代对输入缺失及优化设置的处理。

在固定预测器上，组级 Shapley 分解与局部扰动形成了由模态到片段的解释。文本重编码检验表明，首选候选通常比随机窗口引起更大的预测变化，但这一结论仅对应模型响应。附件 3、4 的全量结果提供了专项样本的预测及解释记录；在缺少专项真值的条件下，不据此估计准确率或宣称解释与真实情绪一致。

参考文献

- [1] Bagher Zadeh A, Liang P P, Poria S, et al. Multimodal Language Analysis in the Wild: CMU-MOSEI Dataset and Interpretable Dynamic Fusion Graph. ACL, 2018: 2236–2246. <https://aclanthology.org/P18-1208/>
- [2] Devlin J, Chang M W, Lee K, Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL-HLT, 2019: 4171–4186. <https://aclanthology.org/N19-1423/>
- [3] audEERING. openSMILE Python Interface Documentation. <https://audeering.github.io/opensmile-python/>（访问日期：2026-09-25）
- [4] librosa development team. librosa documentation. <https://librosa.org/doc/>（访问日期：2026-09-25）
- [5] Google. MediaPipe Face Landmarker Guide. https://ai.google.dev/edge/mediapipe/solutions/vision/face_landmarker（访问日期：2026-09-25）
- [6] Meta AI. wav2vec2-base-960h model card. <https://huggingface.co/facebook/wav2vec2-base-960h>（访问日期：2026-09-25）
- [7] Vaswani A, Shazeer N, Parmar N, et al. Attention Is All You Need. Advances in Neural Information Processing Systems, 2017, 30.
- [8] Fang Y, Huang W, Wan G, Su K, Ye M. EMOE: Modality-Specific Enhanced Dynamic Emotion Experts. CVPR, 2025: 14314–14324. https://openaccess.thecvf.com/content/CVPR2025/papers/Fang_EMOE_Modality-Specific_Enhanced_Dynamic_Emotion_Experts_CVPR_2025_paper.pdf
- [9] Lundberg S M, Lee S I. A Unified Approach to Interpreting Model Predictions. Advances in Neural Information Processing Systems, 2017, 30.
- [10] DeYoung J, Jain S, Rajani N F, et al. ERASER: A Benchmark to Evaluate Rationalized NLP Models. ACL, 2020: 4443–4458. <https://aclanthology.org/2020.acl-main.408/>

附录 A 第一问 100 条样本结果汇总

以下为基础版本。全部样本具有文本 768、音频 70、视觉 61 维表示，对齐参考为词时间区间，输出保留 BERT 子词。表内时长取视频解码元数据；有效音频、视觉位置数为聚合后的 token 数量。完整时间轴、音频解码时长和逐帧向量见配套 JSON 与 NPZ，不由此表替代。

表 A1 第一问 100 条样本基础版清单

样本编号	状态	秒	词数	未解	音频有效	视觉有效
-3g5yACwYnA\$\$_\$13	PASS	5.51	15	0	18	18
-9y-fZ3swSY\$\$_\$4	REVIEW	2.82	9	1	10	10
-yRb-Jum7EQ\$\$_\$1	REVIEW	29.29	49	8	47	47
-3g5yACwYnA\$\$_\$3	PASS	14.39	29	0	40	40
-3g5yACwYnA\$\$_\$2	PASS	9.39	14	0	17	17
-3g5yACwYnA\$\$_\$9	PASS	8.82	21	0	28	28
-3nNcZdcvU\$\$_\$5	PASS	7.87	18	0	22	22
-HwX2H8Z4hY\$\$_\$2	REVIEW	3.98	8	3	8	1
-HwX2H8Z4hY\$\$_\$5	REVIEW	5.65	10	1	9	2
-HwX2H8Z4hY\$\$_\$6	REVIEW	3.36	7	0	9	7
-HwX2H8Z4hY\$\$_\$9	REVIEW	7.73	22	1	23	0
-NFrJFQijFE\$\$_\$1	REVIEW	5.75	16	16	0	0
-NFrJFQijFE\$\$_\$2	REVIEW	6.86	18	12	6	0
-THoVjtIkeU\$\$_\$12	PASS	14.90	39	0	42	42
-THoVjtIkeU\$\$_\$2	PASS	4.29	10	0	11	11
-THoVjtIkeU\$\$_\$6	REVIEW	8.10	30	2	30	30
-UuX1xuaiiE\$\$_\$1	REVIEW	10.35	27	0	33	1
-UuX1xuaiiE\$\$_\$0	REVIEW	3.63	9	1	8	5
-UuX1xuaiiE\$\$_\$3	REVIEW	4.13	9	0	9	9
-UuX1xuaiiE\$\$_\$6	REVIEW	8.11	22	1	22	21
-a55Q6RWvTA\$\$_\$3	REVIEW	22.15	65	1	81	81
-aNfi7CP8vM\$\$_\$7	PASS	8.69	18	0	23	23
-aqamKhZ1Ec\$\$_\$0	REVIEW	10.97	14	2	13	13
-dxftGcXJoc\$\$_\$1	PASS	16.16	36	0	42	42
-dxftGcXJoc\$\$_\$0	REVIEW	20.50	41	3	51	41
-dxftGcXJoc\$\$_\$2	REVIEW	16.70	34	2	36	36
-dxftGcXJoc\$\$_\$6	REVIEW	12.74	27	0	32	32
-egA8-b7-3M\$\$_\$26	PASS	6.03	15	0	19	19
-egA8-b7-3M\$\$_\$17	PASS	7.27	16	0	19	19
-egA8-b7-3M\$\$_\$18	PASS	8.39	22	0	27	27
-egA8-b7-3M\$\$_\$16	PASS	5.54	11	0	13	13
-egA8-b7-3M\$\$_\$13	PASS	4.18	11	0	16	16
-egA8-b7-3M\$\$_\$1	REVIEW	10.27	20	1	20	20
-egA8-b7-3M\$\$_\$6	PASS	6.26	12	0	13	13
-egA8-b7-3M\$\$_\$9	PASS	5.09	10	0	12	12
-egA8-b7-3M\$\$_\$20	PASS	6.64	20	0	24	24
-iRBcNs9oI8\$\$_\$3	REVIEW	5.62	8	2	7	0

样本编号	状态	秒	词数	未解	音频有效	视觉有效
-iRBcNs9oI8\$_\$7	REVIEW	4.10	9	2	13	0
-iRBcNs9oI8\$_\$6	REVIEW	2.90	5	2	3	0
-iRBcNs9oI8\$_\$9	REVIEW	3.42	5	1	4	0
-iRBcNs9oI8\$_\$8	REVIEW	8.09	21	5	20	0
-lzEya4AM_4\$_\$5	REVIEW	7.67	19	1	20	0
-lzEya4AM_4\$_\$6	REVIEW	14.79	43	1	47	0
-mJ2ud6oKI8\$_\$1	REVIEW	6.10	13	13	0	0
-mJ2ud6oKI8\$_\$2	REVIEW	5.73	11	11	0	0
-mJ2ud6oKI8\$_\$6	PASS	2.26	5	0	5	5
-mJ2ud6oKI8\$_\$9	REVIEW	7.03	22	5	23	23
-mJ2ud6oKI8\$_\$8	REVIEW	4.19	11	4	7	7
-mqbVkbCndg\$_\$0	PASS	6.47	12	0	17	17
-t217m2on-s\$_\$2	PASS	5.69	12	0	16	16
-t217m2on-s\$_\$7	PASS	17.18	45	0	53	53
-tANM6ETl_M\$_\$3	REVIEW	6.76	22	1	28	28
-tPCytz4rww\$_\$11	PASS	5.47	17	0	20	20
-tPCytz4rww\$_\$10	PASS	4.79	12	0	15	15
-tPCytz4rww\$_\$12	REVIEW	11.86	26	2	26	26
-tPCytz4rww\$_\$16	PASS	7.21	16	0	17	17
-tPCytz4rww\$_\$18	PASS	6.64	16	0	22	22
-vxjVxOeScU\$_\$4	REVIEW	9.13	21	2	23	23
-wMB_hJL-3o\$_\$7	PASS	6.04	22	0	23	23
-wny0OAz3g8\$_\$1	REVIEW	6.84	23	1	27	8
-wny0OAz3g8\$_\$0	PASS	3.33	9	0	11	11
-wny0OAz3g8\$_\$3	REVIEW	6.15	20	0	20	11
-wny0OAz3g8\$_\$2	PASS	6.69	23	0	28	28
-wny0OAz3g8\$_\$5	REVIEW	6.91	20	0	27	2
-wny0OAz3g8\$_\$7	REVIEW	8.07	29	0	31	30
-wny0OAz3g8\$_\$9	REVIEW	6.21	20	1	21	21
-571d8cVauQ\$_\$0	REVIEW	5.07	12	0	16	0
-571d8cVauQ\$_\$5	REVIEW	15.27	43	0	52	0
-I_e4mlh0yE\$_\$1	PASS	7.62	18	0	21	21
-I_e4mlh0yE\$_\$3	PASS	9.16	22	0	30	30
-UacrmKiTn4\$_\$10	REVIEW	7.36	18	0	22	0
-UacrmKiTn4\$_\$4	REVIEW	4.74	14	0	15	0
-hnBHBN8p5A\$_\$7	REVIEW	7.37	13	4	12	0
-hnBHBN8p5A\$_\$6	REVIEW	6.40	13	2	11	1
-qDkUB0GgYY\$_\$6	REVIEW	4.68	16	1	17	0
-uywlfYOS8\$_\$4	PASS	6.04	18	0	22	22
-6rXp3zJ3kc\$_\$8	PASS	12.81	34	0	38	38
-9y-fZ3swSY\$_\$0	REVIEW	6.83	22	3	25	25
-9y-fZ3swSY\$_\$8	REVIEW	4.99	12	0	14	11
-AUZQgSxyPQ\$_\$2	REVIEW	22.51	41	1	55	55
-HeZS2-Prhc\$_\$2	REVIEW	8.26	16	0	17	0

样本编号	状态	秒	词数	未解	音频有效	视觉有效
-MeTTeMJBNe\$_\$0	REVIEW	9.30	21	0	26	0
-MeTTeMJBNe\$_\$13	REVIEW	5.43	14	0	16	0
-MeTTeMJBNe\$_\$7	REVIEW	10.52	31	0	33	0
-RfYyzHpjk4\$_\$11	PASS	5.24	17	0	19	19
-RfYyzHpjk4\$_\$8	PASS	4.59	17	0	21	21
-RfYyzHpjk4\$_\$2	REVIEW	5.52	25	2	26	26
-UUCSKoHeMAS\$_\$0	REVIEW	7.80	18	0	23	0
-ri04Z7vwnc\$_\$0	REVIEW	2.81	8	6	2	0
-ri04Z7vwnc\$_\$2	REVIEW	6.03	16	14	4	1
-ri04Z7vwnc\$_\$5	REVIEW	3.54	9	5	4	4
-s9qJ7ATP7w\$_\$1	PASS	4.79	11	0	12	12
-s9qJ7ATP7w\$_\$0	REVIEW	6.80	24	1	27	26
-s9qJ7ATP7w\$_\$5	REVIEW	8.56	19	1	19	19
-s9qJ7ATP7w\$_\$4	PASS	4.43	9	0	10	7
-s9qJ7ATP7w\$_\$7	REVIEW	6.97	28	2	36	18
-s9qJ7ATP7w\$_\$6	PASS	2.48	5	0	5	5
-s9qJ7ATP7w\$_\$8	REVIEW	3.29	13	1	16	15
-yRb-Jum7EQ\$_\$5	REVIEW	13.17	25	10	21	21
-yRb-Jum7EQ\$_\$6	REVIEW	11.24	19	6	17	17

附录 B 附件 4 解释摘要

下表类别贡献使用训练均值参考。每条仅列一个主要模态候选，完整候选保留在解释 CSV。时间为 CTC 重建估计；空缺时间表示不可可靠定位，并非没有证据。文本方向检验为正只代表原词干预后的模型响应，不等于人工认可。

表 B1 附件 4 类别贡献与主要模态首选候选

样本	ϕ 文本	ϕ 音频	ϕ 视觉	主模态	候选与定位
01	+0.209	+0.058	+0.087	文本	wear components when 1.22—2.10s; 方向一致
02	-0.087	+0.115	+0.123	视觉	each other's misery. 2.11—2.77s
03	+0.526	-0.013	-0.056	文本	who don't take 4.11—4.99s; 方向一致
04	+0.715	-0.044	-0.080	文本	goodbye?] Absolutely not. 4.48—6.25s; 方向一致
05	-0.051	-0.097	+0.056	视觉	Hi, my name 1.26—2.25s
06	+0.135	-0.113	-0.192	文本	dance, see impressive 3.23—4.41s; 方向一致
07	+0.114	-0.058	-0.041	文本	attendees “enthusiastically discussed 5.00—7.56s; 方向一致
08	+0.193	-0.156	-0.177	文本	Universal Design Grand 2.04—3.69s; 方向一致
09	+0.897	-0.008	-0.011	文本	(uhh) I did 0.48—1.33s; 方向一致
10	+0.861	-0.016	-0.016	文本	was pretty terrible 7.51—9.21s; 方向一致
11	+0.799	+0.012	+0.001	文本	would be ashamed 0.62—1.34s; 方向一致
12	+0.788	-0.019	-0.013	文本	is very low. 11.63—12.27s; 方向一致
13	+0.199	+0.087	+0.000	文本	For example, I 0.00—0.90s; 方向一致
14	+0.327	+0.051	-0.077	文本	Rossen and Vettese 1.58—2.46s; 方向一致
15	+0.198	+0.026	-0.053	文本	power to transform 未定位; 方向一致
16	+0.913	-0.002	-0.000	文本	It's a terrible, 0.48—1.19s; 方向一致
17	+0.311	-0.074	-0.031	文本	easy and will 5.65—6.96s; 方向一致
18	+0.431	+0.006	-0.043	文本	has been denied 8.69—9.43s; 方向一致
19	+0.468	-0.006	-0.061	文本	all over imperfections, 9.53—10.71s; 方向不一致
20	+0.125	-0.016	+0.018	文本	more, and we'll 3.54—4.88s; 方向一致

附录 C 复现范围与材料说明

论文结果来自已保存实验。绘制图表和重新排版不触发新训练，不更改原始数据。第一问采用 `data/processed/q1` 基础版；第二问最终配置为 `configs/q2_final.json` 中的 `C_uni`；第三问为 `q3_c_uni_final_20260925`，不使用历史新结构训练的权重。主要结果的源文件索引随本稿另附。

重新训练需要附件 2 原始特征、固定 BERT 与训练环境；附件 3 推理还需要最终三份模型权重；第三问视频定位需要附件 4 原视频与 CTC 模型。仅读已有 NPZ 和 CSV 可以完成多数统计图，含原画面的图不能只凭源码重画。详细运行命令统一保留在工程根目录《运行使用说明.md》。源码仓库不包含原始数据和预训练权重，不能将仓库下载成功视为完整推理环境已就绪。

历史记录的运行环境为 Python 3.12、PyTorch 2.7.1+cu128、Transformers 5.17.0；BERT 固定 revision 为 86b5e0934494bd15c9632b12f734a8a67f723594。本文未补造未记录的软件版本。最终提交前仍须补齐可用的完整依赖清单、确认 AI 工具实际使用记录、检查官方模板及匿名要求，并验证包含所选特征与共享模型权重的附件总大小。本稿为供队内审阅的研究初稿，不作为这些交付检查已通过的证明。